Глава 4 Кластерный анализ

4.1 Основы кластерного анализа

4.1.1 Основные понятия

В статистических исследованиях группировка первичных данных является основным приемом решения задачи классификации, а поэтому и основой всей дальнейшей работы с собранной информацией.

Традиционно эта задача решается следующим образом. Из множества признаков, описывающих объект, отбирается один, наиболее информативный с точки зрения исследователя, и производится группировка в соответствии со значениями данного признака. Если требуется провести классификацию по нескольким признакам, ранжированным между собой по степени важности, то сначала производится классификация по первому признаку, затем каждый из полученных классов разбивается на подклассы по второму признаку и т.д. Подобным образом строится большинство комбинационных статистических группировок.

В тех случаях, когда не представляется возможным упорядочить классификационные признаки, применяется наиболее простой метод многомерной группировки – создание интегрального показателя (индекса), функционально зависящего от исходных признаков, с последующей классификацией по этому показателю.

Развитием этого подхода является вариант классификации по нескольким обобщающим показателям (главным компонентам), полученным с помощью методов факторного или компонентного анализа.

При наличии нескольких признаков (исходных или обобщенных), задача классификации может быть решена методами *кластерного анализа,* которые отличаются от других методов многомерной классификации отсутствием обучающих выборок, т.е. априорной информации о распределении генеральной совокупности, которая представляет собой вектор X.

Различия между схемами решения задачи по классификации во многом определяются тем, что понимают под понятием “сходство” и “степень сходства”.

После того как сформулирована цель работы, естественно попытаться определить критерии качества, целевую функцию, значения которой позволят сопоставить различные схемы классификации.

В экономических исследованиях целевая функция, как правило, должна минимизировать некоторый параметр, определенный на множестве объектов (например, цель классифицировать оборудование может явиться группировка, минимизирующая совокупность затрат времени и средств на ремонтные работы).

В случаях, когда формализовать цель задачи не удается, критерием качества классификации может служить возможность содержательной интерпретации найденных групп.

Рассмотрим следующую задачу. Пусть исследуется совокупность n объектов, каждый из которых характеризуется по k замеренным на нем признакам X. Требуется разбить эту совокупность на однородные, в некотором смысле, группы (классы).

При этом практически отсутствует априорная информация о характере распределения измерений X внутри классов.

Полученные в результате разбиения группы обычно называются кластерами[♣] (таксонами[♣♣], образами), методы их нахождения – кластер-анализом (соответственно численной таксономией или распознаванием образов с самообучением).

При этом, необходимо с самого начала, четко представить, какая из двух задач классификации подлежит решению. Если решается обычная задача типизации, то совокупность наблюдений разбивают на сравнительно небольшое число областей группирования (например, интервальный вариационный ряд в случае одномерных наблюдений) так, чтобы элементы одной такой области находились друг от друга по возможности на небольшом расстоянии.

Решение другой задачи, заключается в определении естественного расслоения исходных наблюдений на четко выраженные кластеры, лежащие друг от друга на некотором расстоянии.

Если первая задача типизации всегда имеет решение, то при второй постановке, может оказаться, что множество исходных наблюдений не обнаруживает естественного расслоения на кластеры, т.е. образует один кластер.

Хотя, многие методы кластерного анализа довольно элементарны, основная часть работ, в которых они были предложены, относится к последнему десятилетию. Это объясняется тем, что эффективное решение задач поиска кластеров требует большого числа арифметических и логических операций, и поэтому стало возможным только с возникновением и развитием вычислительной техники.

Обычной формой представления исходных данных в задачах кластерного анализа служит прямоугольная таблица:

$$X=\begin{pmatrix} x_{11}\cdots & x_{1j}\cdots & x_{1k} \\ \vdots & \vdots & \vdots \\ x_{i1}\cdots & x_{ij}\cdots & x_{ik} \\ \vdots & \vdots & \vdots \\ x_{n1}\cdots & x_{nj}\cdots & x_{nk} \end{pmatrix},$$

[♣] Claster (англ.) – группа элементов, характеризуемых каким-либо общим свойством.

[♣♣] Taxon (англ.) – систематизированная группа любой категории.

каждая строка которой, представляет результат измерений k, рассматриваемых признаков на одном из обследованных объектов. В конкретных ситуациях, может представлять интерес как группировка объектов, так и группировка признаков. В тех случаях, когда разница между двумя этими задачами не существенна, например, при описании некоторых алгоритмов, мы будем пользоваться только термином “объект”, включая в это понятие и “признак”.

Матрица X не является единственным способом представления данных в задачах кластерного анализа. Иногда, исходная информация задана в виде квадратной матрицы:

$$R=(r_{ij}),\ i,j=1,\ 2,\ ...,\ k,$$

элемент r_{ij} , который определяет степень близости i-го объекта к j-му.

Большинство алгоритмов кластерного анализа полностью исходит из матрицы расстояний (или близостей), либо требует вычисления отдельных ее элементов, поэтому, если данные представлены в форме X, то первым этапом решения задачи поиска кластеров будет выбор способа вычисления расстояний, или близости, между объектами или признаками.

Относительно проще решается вопрос об определении близости между признаками. Как правило, кластерный анализ признаков преследует те же цели, что и факторный анализ – выделение групп связанных между собой признаков, отражающих определенную сторону изучаемых объектов. Мерами близости в этом случае служат различные статистические коэффициенты связи.

4.1.2. Расстояние между объектами (кластерами) и мера близости

Наиболее трудным и наименее формализованным в задаче классификации является определение понятия однородности объектов.

В общем случае, понятие однородности объектов задается либо введение правила вычисления расстояний $\rho(x_i,x_j)$ между любой парой исследуемых объектов $(x_1, x_2, ... , x_n)$, либо заданием некоторой функции $r(x_i,x_j)$, характеризующей степень близости i-го и j-го объектов. Если задана функция $\rho(x_i,x_j)$, то близкие с точки зрения этой метрики объекты считаются однородными, принадлежащими к одному классу. Очевидно, что необходимо при этом сопоставлять $\rho(x_i,x_j)$ с некоторыми пороговыми значениями, определяемыми в каждом конкретном случае по-своему.

Аналогично используется и мера близости $r(x_i,x_j)$, при задании которой мы должны помнить о необходимости выполнения следующих условий: симметрии $r(x_i,x_j)= r(x_j,x_i)$; максимального сходства объекта с самим собой $r(x_i,x_i)= \max\limits_{i\,j} r(x_i,x_j)$, при $1\le i,j\le n$, и монотонного убывания

$r(x_i,x_j)$ по мере увеличения $\rho(x_i,x_j)$, т.е. из $\rho(x_k,x_l)\geq\rho(x_i,x_j)$ должно следовать неравенство $r(x_k,x_l)\leq r(x_i,x_j)$.

Выбор метрики или меры близости является узловым моментом исследования, от которого в основном зависит окончательный вариант разбиения объектов на классы при данном алгоритме разбиения. В каждом, конкретном случае, этот выбор должен производиться по-своему, в зависимости от целей исследования, физической и статистической природы вектора наблюдений X, априорных сведений о характере вероятностного распределения X.

Рассмотрим наиболее широко используемые в задачах кластерного анализа расстояния и меры близости.

Обычное Евклидово расстояние

$$\rho_E(x_i, x_j) = \sqrt{\sum_{e=1}^{k}(x_{ie} - x_{je})^2} \qquad (4.1)$$

где $x_{ie,}$, x_{je} – величина e-ой компоненты у i-го (j-го) объекта (e=1,2,...,к, i,j=1,2,...,n)

Использование этого расстояния оправдано в следующих случаях:

а) наблюдения берутся из генеральной совокупности, имеющей многомерное нормальное распределение с ковариационной матрицей вида $\sigma^2 E_к$, т.е. компоненты X взаимно независимы и имеют одну и ту же дисперсию, где $E_к$ – единичная матрица;

б) компоненты вектора наблюдений X однородны по физическому смыслу и одинаково важны для классификации;

в) признаковое пространство совпадает с геометрическим пространством.

Естественное, с геометрической точки зрения, евклидово пространство может оказаться бессмысленным (с точки зрения содержательной интерпретации), если признаки измерены в разных единицах. Чтобы исправить положение, прибегают к нормированию каждого признака путем деления центрированной величины на среднее квадратическое отклонение и переходят от матрицы X, к нормированной матрице с элементами:

$$t_{ie} = \frac{x_{ie} - \overline{x}_e}{S_e},$$

где, $\overline{X_{ie}}$ – значение e-го признака у i-го объекта;

$\overline{x_e}$ - среднее значение e-го признака;

$S_e = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_{ie} - \overline{x}_e)^2}$ – среднее квадратическое отклонение e-го признака.

Однако, эта операция может привести к нежелательным последствиям. Если, кластеры хорошо разделены по одному признаку, и не разделены по другому, то после нормирования дискриминирующие возможности первого признака, будут уменьшены в связи с увеличением "шумового" эффекта второго.

"Взвешенное" Евклидово пространство

$$\rho_{BE}(x_i, x_e) = \sqrt{\sum_{e=1}^{k} \omega_e (x_{ie} - x_{je})^2} \qquad (4.2)$$

применяется в тех случаях, когда каждой компоненте x_l вектора наблюдений X, удается приписать некоторый "вес" ω_l, пропорционально степени важности признака в задаче классификации. Обычно принимают $0 \le \omega_e \le 1$, где e=1,2,...k.

Определение "весов", как правило, связано с дополнительными исследованиями, например, организацией опроса экспертов и обработкой их мнений. Определение весов ω_l, только по данным выборки, может привести к ложным выводам.

Хеммингово расстояние

Используется как мера различия объектов, задаваемых дихотомическими признаками. Это расстояние определяется по формуле:

$$\rho_H(x_i, x_j) = \sum_{e=1}^{k} \left| x_{ie} - x_{je} \right| \qquad (4.3)$$

и равно числу несовпадений значений соответствующих признаков, в рассматриваемых i-м и j-м объектах.

В некоторых задачах классификации объектов, в качестве меры близости объектов, можно использовать некоторые физические содержательные параметры, так или иначе характеризующие взаимоотношения между объектами. Например, задачу классификации отраслей народного хозяйства, с целью агрегирования, решают на основе матрицы межотраслевого баланса [1].

В данной задаче, объектом классификации является отрасль народного хозяйства, а матрица межотраслевого баланса представлена элементами s_{ij}, характеризующими сумму годовых поставок i-ой отрасли в j-ю, в денежном выражении. В качестве меры близости $\{r_{ij}\}$, принимают симметризованную нормированную матрицу

межотраслевого баланса. С целью нормирования, денежное выражение поставок, i-ой отрасли в j-ю заменяют долей этих поставок по отношению ко всем поставкам i-ой отрасли. Симметризацию, нормированной матрицы межотраслевого баланса можно проводить, выразив близость между i-й и j-й отраслями через среднее значение из взаимных поставок, так что в этом случае $r_{ij}=r_{ji}$.

Как правило, решение задач классификации многомерных данных, предусматривает в качестве предварительного этапа исследования реализацию методов, позволяющих выбрать из компонент x_1, x_2, ..., $x_к$, наблюдаемых векторов X, сравнительно небольшое число наиболее существенно информативных, т.е. уменьшить размерность наблюдаемого пространства.

В ряде процедур классификации (кластер-процедур) используют понятия расстояния между группами объектов и меры близости двух групп объектов.

Пусть, s_i – i-я группа (класс, кластер), состоящая из n_i объектов;

$\bar{x}_i$ – среднее арифметическое векторных наблюдений s_i группы, т.е. "центр тяжести" i-й группы;

$\rho(s_l,s_m)$ – расстояние между группами s_l и s_m.

Наиболее употребительными расстояниями и мерами близости между классами объектов являются:

– расстояние, измеряемое по принципу “ближайшего соседа” –

$$\rho_{min}(S_e, S_m) = \min_{x_i \in S_e, x_j \in S_m} \rho(x_i, x_j); \qquad (4.4)$$

– расстояние, измеряемого по принципу “дальнего соседа” –

$$\rho_{max}(S_e, S_m) = \max_{x_i \in S_e, x_j \in S_m} \rho(x_i, x_j); \qquad (4.5)$$

– расстояние, измеряемое по “центрам тяжести” групп –

$$\rho_{ц.т.}(S_e, S_m) = \rho(\bar{x}_e, \bar{x}_m); \qquad (4.6)$$

– расстояние, измеряемое по принципу “средней связи”, определяется как среднее арифметическое всех попарных расстояний между представителями рассматриваемых групп –

$$\rho_{ср}(S_e, S_m) = \frac{1}{n_e n_m} \sum_{x_i \in S_e} \sum_{x_j \in S_m} \rho(x_i, x_j). \qquad (4.7)$$

Академиком А.Н. Колмогоровым было предложено “обобщенное расстояние” между классами, которое включает в себя, в качестве частных случаев, все рассмотренные выше виды расстояний.

Расстояния между группами элементов особенно важно, в так называемых, агломеративных иерархических кластер-процедурах, так как принцип работы таких алгоритмов состоит в последовательном объединении элементов, а затем и целых групп, сначала самых близких, а затем все более и более отдаленных друг от друга.

При этом расстояние между классами s_l и $s_{(m,q)}$, являющиеся объединением двух других классов s_m и s_q, можно определить по формуле:

$$\rho_{e,(m,q)} = \rho(S_e, S_{(m,q)}) = \alpha\rho_{em} + \beta\rho_{eq} + \gamma\rho_{mq} + \delta(\rho_{em} - \rho_{eq}), \qquad (4.8)$$

где, $\rho_{em} = \rho(S_e, S_m)$; $\rho_{eq} = \rho(S_e, S_q)$ *И* $\rho_{mq} = \rho(S_m, S_q)$

– расстояния между классами s_l, s_m и s_q;

– α, β, δ и γ – числовые коэффициенты, значения которых определяют специфику процедуры, ее алгоритм.

Например, при $\alpha = \beta = -\delta = 1/2$ и $\gamma = 0$ приходим к расстоянию, построенному по принципу “ближайшего соседа”. При $\alpha = \beta = \delta = 1/2$ и $\gamma = 0$ – расстояние между классами определяется по принципу “дальнего соседа”, то есть как расстояние между двумя самыми дальними элементами этих классов.

И, наконец, при:

$$\alpha = \frac{n_m}{n_m + n_q}; \quad \beta = \frac{n_q}{n_m + n_q}, \quad \gamma = \delta = 0$$

соотношение (4.11) приводит к расстоянию $\rho_{ср}$ между классами, вычисленному как среднее из расстояний между всеми парами элементов, один из которых берется из одного класса, а другой из другого.

4.1.3. Функционалы качества разбиения

Существует большое количество различных способов разбиения заданной совокупности элементов на классы. Поэтому представляет интерес, задача сравнительного анализа качества этих способов разбиения Q(S), определенного на множестве всех возможных разбиений.

Тогда, под наилучшим разбиением S^*, понимаем такое разбиение, при котором достигается экстремум выбранного функционала качества. Следует отметить, что выбор того или иного функционала качества, как правило, опирается на эмпирические соображения.

Рассмотрим некоторые наиболее распространенные функционалы качества разбиения. Пусть исследованием выбрана метрика ρ, в пространстве X и пусть $S=(s_1,s_2,...,s_p)$ – некоторое фиксированное разбиение наблюдений $x_1, ...,x_n$ на заданное число p классов $s_1,s_2,...,s_p$.

За функционал качества берут сумму (“взвешенную”) внутриклассовых дисперсий:

$$Q_1(S)=\sum_{e=1}^{p}\sum_{x_i\in S_e}\rho^2(x_i,x_j). \qquad (4.9)$$

4.1.4.Иерархические кластер-процедуры

Иерархические (древообразные) процедуры, являются наиболее распространенными (в смысле реализации на ЭВМ), алгоритмами кластерного анализа. Они бывают двух типов: агломеративные и дивизимные. В агломеративных процедурах начальным является разбиение, состоящее из n-одноэлементных классов, а конечным – из одного класса; в дивизимных – наоборот.

Принцип работы иерархических агломеративных (дивизимных) процедур состоит в последовательном объединении (разделении) групп элементов, сначала самых близких (далеких), а затем все более отдаленных (близких) друг от друга. Большинство этих алгоритмов исходит из матрицы расстояний (сходства).

К недостаткам иерархических процедур следует отнести громоздкость их вычислительной реализации. Алгоритмы требуют вычисления на каждом шаге матрицы расстояний, а следовательно, емкой машинной памяти и большого количества времени. В этой связи, реализация таких алгоритмов при числе наблюдений, большем нескольких сотен, нецелесообразна, а в ряде случаев и невозможна.

В качестве примера рассмотрим агломеративный иерархический алгоритм. На первом шаге алгоритма каждое наблюдение x_i (i=1,2,...n) рассматривается как отдельный кластер. В дальнейшем, на каждом шаге работы алгоритма, происходит объединение двух самых близких кластеров, и с учетом принятого расстояния по формуле пересчитывается матрица расстояний, размерность которой, очевидно, снижается на единицу. Работа алгоритма заканчивается, когда все наблюдения объединены в один класс.

Большинство программ, реализующих алгоритм иерархической классификации, предусматривает графическое представление результатов классификации в виде дендрограммы.

4.2. Тестовый пример

Провести классификацию n=6 объектов, каждый из которых характеризуется двумя признаками.

Номер объекта(i)	*1*	*2*	*3*	*4*	*5*	*6*
x_{i1}	5	6	5	10	11	10
x_{i2}	10	12	13	9	9	7

Расположение этих точек на плоскости показано на рис. 4.1.

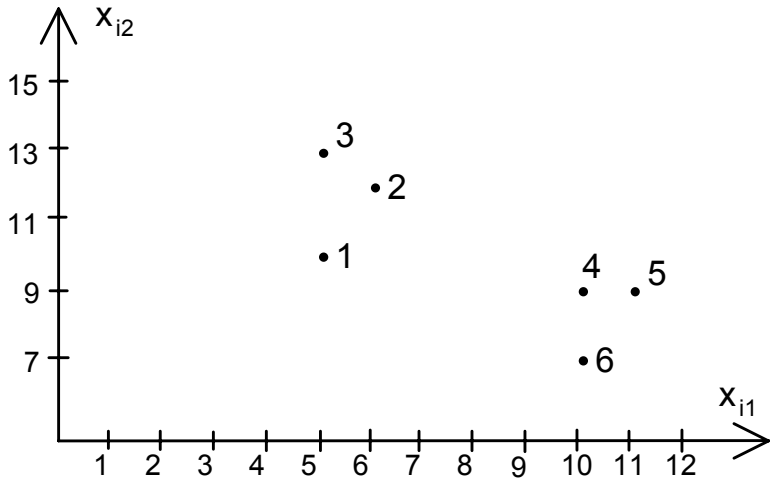


Рис. 4.1

Воспользуемся агломеративным иерархическим алгоритмом классификации. В качестве расстояния между объектами примем обычное евклидово расстояние. Тогда, согласно (4.1), расстояние между объектами 1 и 2 равно:

$$\rho_{12} = \sqrt{(5-6)^2 + (10-12)^2} = 2{,}24,$$

а между объектами 1 и 3 –

$$\rho_{13} = \sqrt{(5-5)^2 + (10-13)^2} = 3,$$

очевидно, что,

$$\rho_{11} = 0.$$

Аналогично находим расстояния между всеми шестью объектами и строим матрицу расстояний:

$$R_1 = \{\rho(x_i, x_j)\} = \begin{pmatrix} 0 & 2,24 & 3 & 5,10 & 6,08 & 5,83 \\ 2,24 & 0 & 1,41 & 5 & 5,83 & 6,40 \\ 3 & 1,41 & 0 & 6,40 & 7,21 & 7,81 \\ 5,10 & 5 & 6,40 & 0 & 1 & 2 \\ 6,08 & 5,83 & 7,21 & 1 & 0 & 2,24 \\ 5,83 & 6,40 & 7,81 & 2 & 2,24 & 0 \end{pmatrix}.$$

Из матрицы расстояний следует, что объекты 4 и 5 наиболее близки $\rho_{4,5}$=1,00 и поэтому объединяются в один кластер.

После объединения имеем пять кластеров.

Номер кластера	1	2	3	4	5
Состав кластера	(1)	(2)	(3)	(4,5)	(6)

Расстояние между кластерами будем находить по принципу “ближайшего соседа”, воспользовавшись формулой пересчета (4.11). Так, расстояние между объектом s_1 и кластером $s_{(4,5)}$, равно:

$$\rho_{1,(4,5)} = \rho(S_1, S_{(4,5)}) = \frac{1}{2}\rho_{14} + \frac{1}{2}\rho_{15} - \frac{1}{2}|\rho_{14} - \rho_{15}| = \frac{1}{2}(5,10 + 6,08) -$$
$$-\frac{1}{2}(|5,10 - 6,08|) = 5,10.$$

Мы видим, что расстояние $\rho_{1,(4,5)}$ равно расстоянию от объекта 1 до ближайшего к нему объекта, входящего в кластер $s_{(4,5)}$, т.е. $\rho_{1,(4,5)} = \rho_{1,4} = 5,10$. Тогда матрица расстояний равна:

$$R_2 = \begin{pmatrix} 0 & 2,24 & 3 & 5,10 & 5,83 \\ 2,24 & 0 & 1,41 & 5 & 6,40 \\ 3 & 1,41 & 0 & 6,40 & 7,81 \\ 5,10 & 5 & 6,40 & 0 & 2 \\ 5,83 & 6,40 & 7,81 & 2 & 0 \end{pmatrix}.$$

Объединим объекты 2 и 3, имеющие наименьшее расстояние $\rho_{2,3}$=1,41. После объединения имеем четыре кластера:

$$s_{(1)}, s_{(2,3)}, \quad s_{(4,5)}, \quad s_{(6)}.$$

Вновь найдем матрицу расстояний. Для этого необходимо рассчитать расстояние до кластера $s_{(2,3)}$. Для этого воспользуемся матрицей расстояний R_2.

Например, расстояние между кластерами

$s_{(4,5)}$ и $s_{(2,3)}$ равно:

$$\rho_{(4,5),(2,3)} = \frac{1}{2}\rho_{(4,5),2} + \frac{1}{2}\rho_{(4,5),3} - \frac{1}{2}\left|\rho_{(4,5),2} - \rho_{(4,5),3}\right| = \frac{5}{2} + \frac{6{,}40}{2} - \frac{1{,}40}{2} = 5 .$$

Проведя аналогичные расчеты, получим:

$$R_3 = \begin{pmatrix} 0 & 2{,}24 & 5{,}10 & 5{,}83 \\ 2{,}24 & 0 & 5 & 6{,}40 \\ 5{,}10 & 5 & 0 & 2 \\ 5{,}83 & 6{,}40 & 2 & 0 \end{pmatrix}.$$

Объединенные кластеры $s_{(4,5)}$ и $s_{(6)}$, расстояние между которыми, согласно матрице R_3, наименьшее: $\rho_{(4,5),6}=2$.

В результате этого получим три кластера: s_1, $s_{(2,3)}$ и $s_{(4,5,6)}$.

Матрица расстояний будет иметь вид:

$$R_4 = \begin{pmatrix} 0 & 2{,}24 & 5{,}10 \\ 2{,}24 & 0 & 5 \\ 5{,}10 & 5 & 0 \end{pmatrix}.$$

Объединим теперь кластеры s_1 и $s_{2,3}$, расстояние между которыми равно $\rho_{1,(2,3)} = 2{,}24$. В результате получим два кластера: $s_{(1,2,3)}$ и $s_{(4,5,6)}$, расстояние между которыми, найденное по принципу “ближайшего соседа”, равно:

$$\rho_{(1,2,3);(4,5,6)} = 5 .$$

Результаты иерархической классификации объектов представлены на рис. 4.2 в виде дендрограммы.

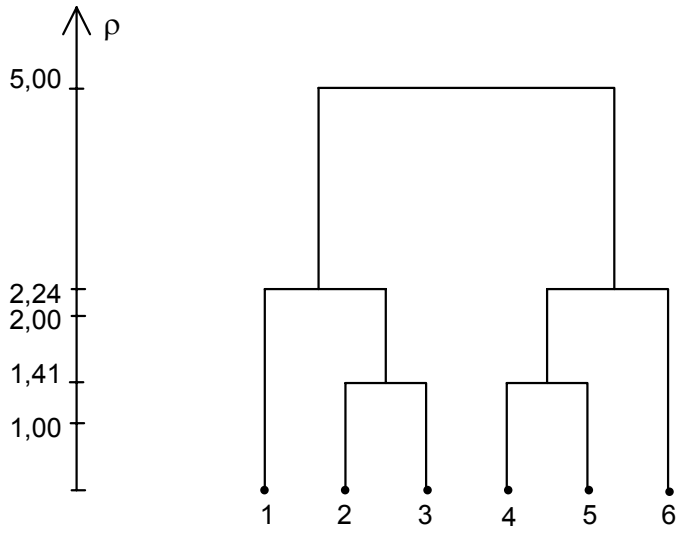


Рис. 4.2. *Дендрограмма*

Слева на рисунке приводится расстояние между объединяемыми на данном этапе кластерами (объектами).

В задаче предпочтение следует отдать предпоследнему этапу классификации, когда все объекты объединены в два кластера:

$$S_{(1,2,3)} \quad \text{и} \quad S_{(4,5,6)},$$

что наглядно видно на рис. 4.1.