

Глава 3. Компонентный анализ

3.1. Основы компонентного анализа

Компонентный анализ предназначен для преобразования системы k исходных признаков, в систему k новых показателей (главных компонент). Главные компоненты не коррелированы между собой и упорядочены по величине их дисперсий, причем, первая главная компонента, имеет наибольшую дисперсию, а последняя, k -я, наименьшую. При этом выявляются неявные, непосредственно не измеряемые, но объективно существующие закономерности, обусловленные действием как внутренних, так и внешних причин.

Компонентный анализ является одним из основных методов факторного анализа. В задачах снижения размерности и классификации обычно используются m первых компонент ($m \ll k$).

При наличии результирующего показателя Y может быть построено уравнение регрессии на главных компонентах.

На основании матрицы исходных данных:

$$X = \begin{pmatrix} X_{11} & \dots & X_{1j} & \dots & X_{1k} \\ X_{i1} & \dots & X_{ij} & \dots & X_{ik} \\ \dots & \dots & \dots & \dots & \dots \\ X_{n1} & \dots & X_{nj} & \dots & X_{nk} \end{pmatrix}$$

размерности $(n \times k)$, где x_{ij} – значение j -го показателя у i -го наблюдения ($i=1,2,\dots,n$; $j=1,2,\dots,k$) вычисляют средние значения показателей $\bar{x}_1, \bar{x}_2, \dots, \bar{x}_k$, а также $s_1, \dots, s_k$ и матрицу нормированных значений:

$$Z = \begin{pmatrix} z_{11} & \dots & z_{1j} & \dots & z_{1k} \\ \dots & \dots & \dots & \dots & \dots \\ z_{i1} & \dots & z_{ij} & \dots & z_{ik} \\ \dots & \dots & \dots & \dots & \dots \\ z_{n1} & \dots & z_{nj} & \dots & z_{nk} \end{pmatrix}$$

с элементами:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Рассчитывается матрица парных коэффициентов корреляции:

$$R = \frac{1}{n} Z^T Z \quad (3.1)$$

с элементами:

$$r_{jl} = \frac{1}{n} \sum_{i=1}^n z_{ij} z_{il} = \frac{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{il} - \bar{x}_l)}{S_j \times S_e} \quad (3.2)$$

где, $j1 = 1, 2, \dots, k$.

На главной диагонали матрицы R , т.е. при $j=1$,

$$r_{jj} = \frac{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}{s_i^2} = 1.$$

Модель компонентного анализа имеет вид:

$$Z_{ij} = \sum_{v=1}^k a_{jv} f_{iv} \quad (3.3)$$

где:

a_{iv} – “вес”, факторная нагрузка, v -ой главной компоненты на j -ой переменной;

f_{iv} – значение v -й главной компоненты для i -го наблюдения (объекта), где $v=1,2, \dots, k$.

В матричной форме модель (3.3) имеет вид:

$$\mathbf{Z} = \mathbf{F} \mathbf{A}^T \quad (3.4)$$

где:

$$F = \begin{pmatrix} f_{11} & \dots & f_{1v} & \dots & f_{1k} \\ \dots & \dots & \dots & \dots & \dots \\ f_{il} & \dots & f_{iv} & \dots & f_{ik} \\ \dots & \dots & \dots & \dots & \dots \\ f_{nl} & \dots & f_{nv} & \dots & f_{nk} \end{pmatrix}$$

– матрица значений главных компонент размерности k)

[illegible]

A^T – транспонированная матрица A ;

f_{iv} – значение v -й главной компоненты у i -го наблюдения (объекта);

a_{jv} – значение факторной нагрузки v -й главной компоненты на j -й переменной.

Матрица F описывает n наблюдений в пространстве k главных компонент. При этом элементы матрицы F нормированы, то есть:
 $\overline{f_v} = \frac{1}{n} \sum_{i=1}^n f_{iv} = 0$, $S_{f_v}^2 = \frac{1}{n} \sum_{i=1}^n f_{iv}^2 = 1$, а главные компоненты не коррелированы между собой. Из этого следует, что,

$$(1/n) F^T F = E \quad (3.5)$$

где,

$$E = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \text{ — единичная матрица размерности } (k \times k).$$

Выражение (3.5) может быть также представлено в виде:

$$\frac{1}{n} \sum_{i=1}^n f_{iv} f_{iv'} = \begin{cases} 1 & \text{при } v = v' \\ 0 & \text{при } v \neq v' \end{cases} \quad (3.6)$$

$$v, v' = 1, 2, \dots, k.$$

С целью интерпретации элементов матрицы A , рассмотрим выражение для парного коэффициента корреляции, между Z_j -переменной и, например, f_1 -й главной компонентой. Так как, z_j и f_1 нормированы, будем иметь с учетом (3.3.):

$$r_{z_j f_1} = \frac{1}{n} \sum_{i=1}^n z_{ij} f_{i1} = \frac{1}{n} \sum_{i=1}^n \left(\sum_{v=1}^k a_{jv} f_{iv} \right) f_{i1} = a_{j1} \frac{1}{n} \sum_{i=1}^n f_{i1}^2 + \sum_{v=2}^k a_{jv} \left(\frac{1}{n} \sum_{i=1}^n f_{i1} f_{iv} \right).$$

Принимая во внимание (3.6), окончательно получим:

$$r_{z_j f_v} = a_{jv}.$$

Рассуждая аналогично, можно записать в общем виде:

$$r_{z_j f_v} = a_{jv} \quad (3.7)$$

для всех $j=1, 2, \dots, k$ и $v=1, 2, \dots, k$.

Таким образом, элемент a_{jv} матрицы факторных нагрузок A , характеризует тесноту линейной связи между Z_j -исходной переменной и f_v -й главной компонентой, то есть $-1 \leq a_{jv} \leq +1$.

Рассмотрим теперь выражение для дисперсии z_j -й нормированной переменной. С учетом (3.3) будем иметь:

$$\begin{aligned} S_j^2 &= \frac{1}{n} \sum_{i=1}^n z_{ij}^2 = \frac{1}{n} \sum_{i=1}^n \left(\sum_{v=1}^k a_{jv} f_{iv} \right)^2 = \frac{1}{n} \sum_{i=1}^n \left[\sum_{v=1}^k a_{jv}^2 f_{iv}^2 + 2 \sum_{v \neq v'} a_{jv} a_{jv'} \times f_{iv} f_{iv'} \right] = \\ &= \sum_{v=1}^k a_{jv}^2 \left(\frac{1}{n} \sum_{i=1}^n f_{iv}^2 \right) + 2 \sum_{v \neq v'} a_{jv} a_{jv'} \left(\frac{1}{n} \sum_{i=1}^n f_{iv} f_{iv'} \right), \end{aligned}$$

где $v, v'=1, 2, \dots, k$.

Учитывая (3.6), окончательно получим:

$$S_j^2 = \sum_{v=1}^k a_{jv}^2 = 1. \quad (3.8)$$

По условию переменные z_j нормированы и $s_j^2=1$. Таким образом, дисперсия z_j -й переменной согласно (3.8), представлена своими составляющими, определяющими долю вклада в нее всех k главных компонент.

Полный вклад v -й главной компоненты в дисперсию всех k исходных признаков вычисляется по формуле:

$$\lambda_k = \sum_{j=1}^k a_{jv}^2. \quad (3.9)$$

Одно из основополагающих условий метода главных компонент, связано с представлением корреляционной матрицы R , через матрицу факторных нагрузок A . Подставив для этого (3.4) в (3.1), будем иметь:

$$R = (1/n) Z^T Z = (1/n) (F A^T)^T F A^T = A ((1/n) F^T F) A^T.$$

Учитывая (3.5), окончательно получим:

$$R = A A^T \quad (3.10)$$

Перейдем теперь непосредственно к отысканию собственных значений и собственных векторов корреляционной матрицы R .

Из линейной алгебры известно, что для любой симметрической матрицы R , всегда существует такая ортогональная матрица U , что выполняется условие:

$$U^T R U = \Lambda, \quad (3.11)$$

где,

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \lambda_k \end{pmatrix} \text{ – диагональная матрица собственных значений размерности } (k \times k);$$

$$U = \begin{pmatrix} u_{11} & \dots & u_{1v} & \dots & u_{1k} \\ \dots & \dots & \dots & \dots & \dots \\ u_{j1} & \dots & u_{jv} & \dots & u_{jk} \\ \dots & \dots & \dots & \dots & \dots \\ u_{k1} & \dots & u_{kv} & \dots & u_{kk} \end{pmatrix} \text{ – ортогональная матрица собственных векторов размерности } (k \times k).$$

Так как матрица R положительно определена, т.е. ее главные миноры положительны, то все собственные значения положительны – $\lambda_v > 0$ для всех $v=1, 2, \dots, K$.

В компонентном анализе элементы матрицы Λ ранжированы $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_v \geq \dots \geq \lambda_k > 0$. Как будет показано ниже, собственное значение λ_v характеризует вклад v -й главной компоненты в суммарную дисперсию исходного признакового пространства.

Таким образом, первая главная компонента вносит наибольший вклад в суммарную дисперсию, а последняя k -я – наименьший.

В ортогональной матрице U собственных векторов, v -й столбец является собственным вектором, соответствующим λ_v -му значению.

Собственные значения $\lambda_1 \geq \dots \geq \lambda_v \geq \dots \geq \lambda_k$ находятся как корни характеристического уравнения:

$$|\Lambda E - R| = 0. \quad (3.12)$$

Собственный вектор V_v , соответствующий собственному значению λ_v корреляционной матрицы R , определяется как отличное от нуля решение уравнения, которое следует из (3.11):

$$(\lambda_v E - R)V_v = 0. \quad (3.13)$$

Нормированный собственный вектор U_v равен:

$$U_v = \frac{V_v}{\sqrt{V_v^T V_v}}.$$

Из условия ортогональности матрицы U следует, что $U^{-1}=U^T$, но тогда по определению матрицы R и Λ подобны, так как они согласно (3.11) удовлетворяют условию:

$$U^{-1}RU=\Lambda.$$

Так как следы, т.е. суммы диагональных элементов у подобных матриц равны, то:

$$\text{tr}\Lambda=\text{tr}(U^{-1}RU)=\text{tr}[R(UU^{-1})]=\text{tr}R.$$

Напомним из линейной алгебры, что умножение матрицы U на обратную матрицу U^{-1} , дает единичную матрицу E . Следы матричных произведений $(U^{-1}) \times (RU)$ и $R \times (UU^{-1})$ также равны.

Учитывая, что сумма диагональных элементов матрицы R равна k , будем иметь:

$$\text{tr}\Lambda=\text{tr}R=k.$$

Таким образом,

$$\sum_{v=1}^k \lambda_v = k. \quad (3.14)$$

Представим матрицу факторных нагрузок A в виде:

$$A=UA^{1/2}, \quad (3.15)$$

а v -й столбец матрицы A :

$$Av=Uv \cdot \lambda_v^{1/2},$$

где U_v – собственный вектор матрицы R , соответствующий собственному значению λ_v .

Найдем норму вектора A_v :

$$|A_v|^2=A_v^T A_v=\lambda_v^{1/2} U_v^T U_v \lambda_v^{1/2}=\lambda_v. \quad (3.16)$$

Здесь учитывалось, что вектор U_v нормированный и $U_v^T U_v=1$. Таким образом,

$$\lambda_v = \sum_{j=1}^k a_{jv}^2.$$

Сравнив полученный результат с (3.9), можно сделать вывод, что собственное значение λ_v характеризует вклад v -й главной компоненты в суммарную дисперсию всех исходных признаков. Из (3.15) следует:

$$A^T A = \Lambda \quad (3.17)$$

Согласно (3.14) общий вклад всех главных компонент в суммарную дисперсию равен k . Тогда удельный вклад v -й главной компоненты определяется по формуле:

$$\frac{\lambda_v}{k} 100\%.$$

Суммарный вклад m первых главных компонент определяется из выражения:

$$\frac{\sum_{v=1}^m \lambda_v}{k} 100\%.$$

Обычно для анализа используют m первых главных компонент, суммарный вклад которых превышает 60–70%.

Матрица факторных нагрузок A используется для экономической интерпретации главных компонент, которые представляют линейные функции исходных признаков. Для экономической интерпретации f_v используются лишь те x_j , для которых, $|a_{jv}| > 0,5$.

Значения главных компонент для каждого i -го объекта ($i=1,2,\dots,n$) задаются матрицей F .

Матрицу значений главных компонент можно получить из формулы:

$$Z = F A^T,$$

откуда,

$$F = Z (A^T)^{-1} = Z V \Lambda^{-1/2},$$

где,

$$F = \begin{pmatrix} f_{11} \dots f_{1v} \dots f_{1k} \\ \dots \dots \dots \\ f_{i1} \dots f_{iv} \dots f_{ik} \\ \dots \dots \dots \\ f_{n1} \dots f_{nv} \dots f_{nk} \end{pmatrix}$$

Z – матрица нормированных значений исходных показателей.

Уравнение регрессии на главных компонентах строится по алгоритму пошагового регрессионного анализа, где в качестве аргументов используются главные компоненты, а не исходные показатели. К достоинству последней модели следует отнести тот факт, что главные компоненты не коррелированы. При построении уравнений регрессии следует учитывать все главные компоненты.

3.2. Тренировочный пример

По данным о численности (x_1) и фонде зарплаты (x_2) пяти ($n=5$) строительных организаций провести компонентный анализ.

$$X = \begin{pmatrix} 3 & 4 \\ 6 & 5 \\ 8 & 9 \\ 2 & 3 \\ 7 & 6 \end{pmatrix}$$

Решение: Рассчитаем выборочные характеристики переменных x_1 и x_2 :

$$\begin{aligned} \bar{x}_1 &= 5,2 & S_1 &= 2,315 \\ \bar{x}_2 &= 5,4 & S_2 &= 2,059 \end{aligned}$$

Выборочный коэффициент корреляции равен:

$$r = \frac{\overline{x_1 x_2} - \bar{x}_1 \cdot \bar{x}_2}{S_1 \cdot S_2} = \frac{32,4 - 5,2 \cdot 5,4}{2,315 \cdot 2,059} = 0,906,$$

преобразуем матрицу X в матрицу нормированных значений Z , с элементами: $z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$, где $i=1,2,3,4,5$; $j=1,2$.

$$Z = \begin{pmatrix} -0,950 & -0,680 \\ 0,346 & -0,194 \\ 1,210 & 1,748 \\ -1,382 & -1,166 \\ 0,778 & 0,291 \end{pmatrix}$$

Матрица парных коэффициентов корреляции имеет вид:

$$R = \begin{pmatrix} 1 & 0,906 \\ 0,906 & 1 \end{pmatrix}$$

Для определения собственных значений матрицы R , рассмотрим характеристическое уравнение (3.12).

$$\left| \begin{pmatrix} \lambda & 0 \\ 0 & \lambda \end{pmatrix} - \begin{pmatrix} 1 & 0,906 \\ 0,906 & 1 \end{pmatrix} \right| = \left| \begin{pmatrix} 1-\lambda & 0,906 \\ 0,906 & 1-\lambda \end{pmatrix} \right| = 0$$

Отсюда следует,

$$(1-\lambda)^2 - (0,906)^2 = 0 \quad \text{или} \quad (1-\lambda) = \pm 0,906,$$

Т.к. по условию компонентного анализа $\lambda_1 > \lambda_2$, то $\lambda_1 = 1,9062$,
 $\lambda_2 = 0,0938$,

где λ_1, λ_2 соответственно дисперсии и вклад 1-й и 2-й главных компонент в суммарную дисперсию, равную $\lambda_1 + \lambda_2 = k = 2$.

Относительный вклад компонент в суммарную дисперсию равен :

$$\frac{\lambda_1}{k} 100\% = \frac{1,906}{2} 100\% = 95,3\%$$

$$\frac{\lambda_2}{k} 100\% = \frac{0,094}{2} 100\% = 4,7\%$$

Таким образом,

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix} = \begin{pmatrix} 1,9062 & 0 \\ 0 & 0,0938 \end{pmatrix}.$$

Определим матрицу собственных векторов из уравнения $(R - \lambda E)V = 0$.

Откуда собственный вектор V_1 находим из условия:

$$\begin{pmatrix} 1-\lambda_1 & r \\ r & 1-\lambda_1 \end{pmatrix} \begin{pmatrix} V_{11} \\ V_{21} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

где,

$$V_1 = \begin{pmatrix} v_{11} \\ v_{21} \end{pmatrix}.$$

Подставляя полученные значения получим:

$$\begin{pmatrix} 0,9062 & 0,9062 \\ 0,9062 & 0,9062 \end{pmatrix} \begin{pmatrix} v_{12} \\ v_{21} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Откуда, $-0,9062v_{11} + 0,9062v_{21} = 0$ или $v_{11} = v_{21} = 1$, т.е. $v_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.

Нормированный собственный вектор, соответствующий λ_1 , равен:

$$U_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

Собственный вектор v_2 найдем решая уравнение:

$$\begin{pmatrix} 0,9062 & 0,9062 \\ 0,9062 & 0,9062 \end{pmatrix} \begin{pmatrix} v_{12} \\ v_{22} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

Откуда, $0,9062V_{12} + 0,9062V_{22} = 0$ или $-V_{12} = V_{22}$, $V_2 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$.

Нормированный собственный вектор, соответствующий λ_2 равен:

$$U_2 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix},$$

тогда нормированная матрица собственных векторов имеет вид:

$$U = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} = \begin{pmatrix} 0,707 & -0,707 \\ 0,707 & 0,707 \end{pmatrix}.$$

Матрицу факторных нагрузок найдем по формуле:

$$A=U\Lambda^{1/2}, \text{ где } \Lambda^{1/2}=\begin{pmatrix} \sqrt{\lambda_1} & 0 \\ 0 & \sqrt{\lambda_2} \end{pmatrix}.$$

Подставив полученные значения, получим:

$$A=\begin{pmatrix} 0,707 & -0,707 \\ 0,707 & 0,707 \end{pmatrix} \times \begin{pmatrix} 1,3807 & 0 \\ 0 & 0,3063 \end{pmatrix} = \begin{pmatrix} 0,9763 & -0,2166 \\ 0,9763 & 0,2166 \end{pmatrix}.$$

Матрицу факторных нагрузок используют для интерпретации главных компонент, т.к. элементы матрицы $a_{jv}=r_{jv}$ характеризуют тесноту связи между x_j -м признаком и f_v главной компонентой. В нашем примере первая главная компонента тесно связана с показателями X_1 и X_2 , f_1 – характеризует размер предприятия.

Матрицу значений главных компонент F можно получить по формуле:

$$F = Z(A^T)^{-1}$$

Предварительно найдем обратную матрицу $(A^T)^{-1}$

Так как,

$$A^T = \begin{pmatrix} 0,9763 & 0,9763 \\ 0,2166 & -0,2166 \end{pmatrix},$$

то,

$$(A^T)^{-1} = \frac{-1}{0,4229} \begin{pmatrix} -0,2166 & -0,9763 \\ -0,2166 & 0,9763 \end{pmatrix} = \begin{pmatrix} 0,5121 & -2,3084 \\ 0,5121 & 2,3084 \end{pmatrix}$$

Тогда,

$$F = \begin{pmatrix} -0,9503 & -0,6799 \\ 0,3456 & -0,1943 \\ 1,2095 & 1,7484 \\ -1,3823 & -1,1656 \\ 0,7775 & 0,2914 \end{pmatrix} \times \begin{pmatrix} 0,5121 & -2,3084 \\ 0,5121 & 2,3084 \end{pmatrix} = \begin{pmatrix} -0,835 & 0,624 \\ 0,077 & -1,246 \\ 1,515 & 1,244 \\ -1,305 & 0,500 \\ 0,547 & -1,122 \end{pmatrix}.$$

Как уже отмечалось, матрица F , которую мы получили, характеризует пять строительных организаций в пространстве главных компонент. Ее можно использовать в задачах классификации и регрессионного анализа. Например, классификация организаций по

первой главной компоненте f_1 , характеризующих размер предприятия, позволяет их ранжировать в порядке возрастания следующим образом: 1; 4; 2; 5; 3, что согласуется с матрицей X.

3.3. Тренировочный пример

По данным примера 1.2.3 провести компонентный анализ и построить уравнение регрессии урожайности Y на главные компоненты.

Решение: В примере 1.2.2. пошаговая процедура регрессионного анализа позволила исключить отрицательное влияние мультиколлинеарности на качество регрессионной модели, за счет значительной потери информации. Из 5 исходных показателей-аргументов в нашу, окончательную модель, вошли только два (x_1 и x_4). Более рациональным в условиях мультиколлинеарности, можно считать построение уравнения регрессии на главных компонентах, которые являются линейными функциями от всех исходных показателей и не коррелированы между собой.

Воспользовавшись методом главных компонент, найдем собственные значения, и на их основе вклад главных компонент в суммарную дисперсию исходных показателей X_1, X_2, X_3, X_4, X_5 (табл.3.1).

Таблица 3.1

Собственные значения главных компонент

Главные компоненты f_v	f_1	f_2	f_3	f_4	f_5
Собственные значения λ_v	3.04	1.41	0.43	0.10	0.02
Относительный вклад v -й главной компоненты (%) в суммарную дисперсию	60.8	28.2	8.6	2.0	0.4
Относительный вклад первых главных компонент (%)	60.8	89.0	97.6	99.6	100.0

Ограничимся экономической интерпретацией двух первых главных компонент, общий вклад которых, в суммарную дисперсию составляет 89.0%. В матрице факторных нагрузок А:

$$A = \begin{bmatrix} 0,95^* & -0,19 & -0,18 & -0,15 & -0,08 \\ 0,94^* & -0,17 & 0,18 & 0,26 & -0,02 \\ 0,94^* & -0,28 & -0,15 & -0,06 & 0,09 \\ 0,24 & 0,88^* & -0,39 & 0,08 & 0,00 \\ 0,56 & 0,67^* & 0,43 & -0,11 & 0,01 \end{bmatrix},$$

звездочкой (*) указаны элементы $a_{jv}=r_{xjfv}$, учитывающиеся при интерпретации главных компонент f_v , где $j, v=1, 2, \dots 5$.

Из матрицы факторной нагрузки А следует, что первая главная компонента наиболее тесно связана с показателями: X_1 – число колесных тракторов ($a_{11}=r_{x1f1}=0,95$); X_2 – число зерноуборочных комбайнов ($r_{x2f1}=0,97$); X_3 – число орудий поверхностной обработки почвы на 100 га ($r_{x3f1}=0,94$). В этой связи, первая главная компонента f_1 , интерпретирована как уровень механизации работ.

Вторая главная компонента f_2 , тесно связана с количеством удобрения (X_4) и средств защиты растений (X_5), расходуемых на гектар и f_2 была интерпретирована как уровень химизации растениеводства.

Уравнение регрессии на главных компонентах строится по данным вектора значений результативного показателя Y и матрицы значений главных компонент F , представленных в таблице 3.2

Таблица 3.2

Значения главных компонент

№ п\п	Y	f_1	f_2	f_3	f_4	f_5
1	9.70	-0.42	-0.52	-0.46	-0.95	0.76
2	8.40	-0.09	1.52	2.18	-0.88	1.42
3	9.00	0.27	-0.35	0.72	0.02	-1.49
4	9.90	1.98	-0.03	1.70	1.35	0.88
5	9.60	-0.29	-0.38	-0.69	-1.28	-0.33
6	8.60	0.04	-0.64	-0.13	0.47	-0.20
7	12.50	0.40	-0.01	0.37	1.24	-0.51
8	7.60	-0.89	-0.70	0.02	0.24	-0.11
9	6.90	-1.00	-0.68	-0.18	-0.95	0.18
10	13.50	1.15	2.79	-0.44	-0.31	-0.81
11	9.70	0.14	0.17	-1.33	1.59	2.01
12	10.70	0.24	-0.97	-0.03	1.22	-0.06
13	12.10	3.08	-1.35	-0.96	-1.74	0.02
14	9.70	-0.09	0.48	-1.64	1.01	0.59
15	7.00	-0.38	-0.26	1.90	-0.01	-0.27
16	7.20	-0.87	-0.74	0.78	-0.35	-0.01
17	8.20	-0.37	-0.96	-0.07	0.74	-1.82
18	8.40	-1.08	0.21	-0.25	-1.71	1.24
19	13.10	-0.80	0.73	-0.86	0.59	0.46
20	8.70	-0.24	1.70	-0.63	-0.27	-1.93

Некоррелированность главных компонент между собой и тесноту их связи с результативным показателем Y , показывает матрица парных коэффициентов корреляции (табл.3.3).

Таблица 3.3

Матрица парных коэффициентов корреляции

№ п/ п	Y	f_1	f_2	f_3	f_4	f_5
Y	1.00	0.48	0.34	-0.37	0.18	0.01
f_1	0.48	1.00	0.00	0.00	0.00	-0.00
f_2	0.34	0.00	1.00	-0.00	0.00	-0.00
f_3	-0.37	0.00	-0.00	1.00	0.00	-0.00
f_4	0.18	0.00	0.00	0.00	1.00	-0.00
f_5	0.01	-0.00	-0.00	-0.00	-0.00	1.00

Из матрицы парных коэффициентов корреляции следует, что Y наиболее тесно связан с первой ($r_{yf1}=0.48$), третьей ($r_{yf3}=-0.37$) и второй ($r_{yf2}=0.34$) главными компонентами. Можно предположить, что только эти главные компоненты войдут в регрессионную модель Y .

Первоначально в модель Y включили все главные компоненты:

$$\hat{Y} = 9.52 + 0.93f_1 + 0.66f_2 - 0.71f_3 + 0.34f_4 + 0.01f_5 \quad (3.19)$$

(26.6) (2.59) (1.85) (-1.99) (0.95) (0.03)

В скобках указаны расчетные значения t-критерия.

Качество модели характеризует множественный коэффициент детерминации $r_y^2=0,517$, средняя относительная ошибка аппроксимации $\bar{\delta}=10.4\%$, остаточная дисперсия $S^2=1.79$ и $F_{\text{набл}}=121$.

В виду того, что $F_{\text{набл}} > F_{\text{кр}}$ ($\alpha=0.05$; $\nu_1=6$; $\nu_2=14$)=2.85, то уравнение регрессии значимо и хотя бы один из коэффициентов регрессии $\beta_1, \beta_2, \beta_3, \beta_4$ не равен нулю.

Если значимость уравнения регрессии ($H_0: \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$) проверялась при $\alpha=0.05$, то значимость коэффициентов регрессии, т.е. гипотезы $H_0: \beta_j=0$ ($j=1, 2, 3, 4$) следует проверять при уровне значимости большим 0.05. Например, при $\alpha=0.1$. Тогда, $t_{\text{кр}}$ ($\alpha=0.1$; $\nu=14$)=1.76 и значимыми, как следует из уравнения (3.19) являются коэффициенты регрессии $\beta_1, \beta_2, \beta_3$.

Учитывая, что главные компоненты не коррелированы между собой, можно сразу исключить из уравнения все не значимые коэффициенты и уравнение примет вид:

$$\hat{Y} = 9.52 + 0.93f_1 + 0.66f_2 - 0.71f_3 \quad (3.20)$$

(27.6) (2.68) (1.92) (-2.06)

Сравнив уравнения (3.19) и (3.20) видим, что исключение не значимых главных компонент f_4 и f_5 не отразилось на значениях коэффициентов уравнения $b_0=9.52$; $b_1=0.93$ и $b_2=0.66$ и соответствующих t_j ($j=0, 1, 2, 3$).

Это обусловлено некоррелированностью главных компонент. Здесь интересна параллель уравнений регрессии по исходным показателям (2.15), (2.16) и главным компонентам (3.19), (3.20).

Уравнение (3.20) значимо $F_{\text{набл}}=194 > F_{\text{кр}}(\alpha=0.05; \nu_1=4; \nu_2=16)=3.01$. Значимы и коэффициенты уравнения, $|t_j| > t_{\text{кр}}(\alpha=0.01; \nu=16)=1.746$ для $j=0, 1, 2, 3$. Коэффициент детерминации $r^2_{(y)}=0.486$ свидетельствует, что 48.6% вариации обусловлено влиянием трех первых главных компонент.

Уравнение характеризуется средней относительной ошибкой аппроксимации $\delta=9.99\%$ и остаточной дисперсией $S^2=1.91$.

Уравнение регрессии на главных компонентах (3.20) обладает несколькими лучшими аппроксимирующими свойствами по сравнению с регрессионной моделью (2.16) по исходным показателям: $r^2_{y(f)}=0.486 > r^2_{y(x)}=0.469$; $\bar{\delta}_{(f)}=9.99\% < \bar{\delta}_{(x)}=10.5\%$ и $S^2_{(f)}=1.91 < S^2_{(x)}=1.97$. Кроме того, в уравнении (3.20) главные компоненты являются линейными функциями всех исходных показателей, в то время как в уравнение (2.16) входят только две переменные (x_1 и x_4). В ряде случаев приходится учитывать, что модель (3.20) трудно интерпретируема, т.к. в нее входит третья главная компонента f_3 , которая нами не интерпретирована и вклад которой в суммарную дисперсию исходных показателей ($X_1 \dots X_5$) всего 8.6%. Однако, исключение f_3 из уравнения (3.20), значительно ухудшает аппроксимирующие свойства модели: $r^2_{y(f)}=0.349$; $S_{(f)}=12.4\%$ и $S^2_{(f)}=2.41$. Тогда, в качестве регрессионной модели урожайности, целесообразно выбрать уравнение (2.16).