

Глава 1. Корреляционный анализ

1.1. Основы корреляционного анализа

Корреляционный анализ является одним из методов статистического анализа взаимозависимости нескольких признаков. Он применяется тогда, когда данные наблюдений можно считать случайными и выбранными из генеральной совокупности, распределенной по многомерному нормальному закону. Основная задача корреляционного анализа состоит в оценке корреляционной матрицы генеральной совокупности по выборке и определении на ее основе оценок частных и множественных коэффициентов корреляции и детерминации.

Парный (частный) коэффициент корреляции характеризует тесноту линейной зависимости между двумя переменными соответственно на фоне действия (при исключении влияния) всех остальных показателей, входящих в модель. Они изменяются в пределах от -1 до +1, причем, чем ближе коэффициент корреляции к ± 1 , тем сильнее зависимость между переменными. Если коэффициент корреляции больше 0, то связь положительная, а если меньше нуля – отрицательная.

Множественный коэффициент корреляции характеризует тесноту линейной связи между одной переменной (результативной) и остальными, входящими в модель; изменяется в пределах от 0 до 1. Квадрат множественного коэффициента корреляции называется множественным коэффициентом детерминации. Он характеризует долю дисперсии одной переменной (результативной), обусловленной влиянием всех остальных (аргументов), входящих в модель.

Исходной для анализа является матрица:

$$X = \begin{pmatrix} x_{11} & \dots & x_{1j} & \dots & x_{1k} \\ \dots & \dots & \dots & \dots & \dots \\ x_{i1} & \dots & x_{ij} & \dots & x_{ik} \\ \dots & \dots & \dots & \dots & \dots \\ x_{n1} & \dots & x_{nj} & \dots & x_{nk} \end{pmatrix}$$

размерности $(n \times k)$, i -я строка которой характеризует i -е наблюдение (объект) по всем k -м показателям ($j=1, 2, \dots, k$).

В корреляционном анализе матрицу X рассматривают как выборку объема n , из k -мерной генеральной совокупности, подчиняющейся k -мерному нормальному закону распределения.

По выборке определяются оценки параметров генеральной совокупности, а именно: вектор средних $(\bar{x})$, вектор средне-квадратических отклонений s и корреляционная матрица (R) порядка k :

$$\bar{x} = \begin{pmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \cdot \\ \cdot \\ \cdot \\ \bar{x}_k \end{pmatrix}, \quad s = \begin{pmatrix} s_1 \\ s_2 \\ \cdot \\ \cdot \\ \cdot \\ s_k \end{pmatrix}, \quad R = \begin{pmatrix} 1 & r_{12} & \dots & r_{1k} \\ r_{21} & 1 & \dots & r_{2k} \\ \dots & \dots & \dots & \dots \\ r_{k1} & r_{k2} & \dots & 1 \end{pmatrix}.$$

Матрица R является симметричной ($r_{jl} = r_{lj}$) и положительно определенной, где:

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad s_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}, \quad (1.1)$$

$$r_{jl} = \frac{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{il} - \bar{x}_l)}{s_j s_l} \quad (1.2)$$

x_{ij} – значение i -го наблюдения j -го фактора; r_{je} – выборочный парный коэффициент корреляции, характеризует тесноту линейной связи между показателями x_j и x_e . При этом r_{je} является оценкой генерального парного коэффициента корреляции.

Кроме того, находятся точечные оценки частных и множественных коэффициентов корреляции любого порядка. Например, частный коэффициент корреляции $(k-2)$ -го порядка между факторами X_1 и X_2

$$r_{1,2/3,4\dots k} = -\frac{R_{12}}{\sqrt{R_{11}R_{22}}}, \quad (1.3)$$

где R_{jl} – алгебраическое дополнение элемента r_{jl} корреляционной матрицы R. При этом, $R_{jl} = (-1)^{j+l} \times M_{jl}$, где M_{jl} – минор, определитель матрицы, получаемой из матрицы R, путем вычеркивания j -й строки и l -го столбца.

Множественный коэффициент корреляции $(k-1)$ -го порядка фактора (результативного признака) X_1 определяется по формуле:

$$r_{1/2,3,4\dots k} = r_1 = \sqrt{1 - \frac{|R|}{R_{11}}}, \quad (1.4)$$

Где $|R|$ – определитель матрицы R.

Значимость частных и парных коэффициентов корреляции, т. е. гипотеза $H_0: \rho=0$, проверяется по t-критерию Стьюдента. Наблюдаемое значение критерия находится по формуле:

$$t_{\text{набл}} = \frac{r}{\sqrt{1-r^2}} \sqrt{n-l-2}, \quad (1.5)$$

где r – соответственно оценка частного или парного коэффициента корреляции; l – порядок частного коэффициента корреляции, т. е. число фиксируемых факторов. Для парного коэффициента корреляции $l=0$.

Напомним, что проверяемый коэффициент корреляции считается значимым, т. е. гипотеза $H_0: \rho=0$ отвергается с вероятностью ошибки α , если $t_{\text{набл}}$ по модулю будет больше, чем $t_{\text{кр}}$, определяемое по таблицам t -распределения (см. приложения) для заданного α и $\nu = n - l - 2$.

Значимость коэффициентов корреляции можно также проверить с помощью таблиц Фишера-Иейтса (табл. 5 приложения).

При определении с надежностью γ доверительного интервала для значимого парного или частного коэффициентов корреляции ρ , используют Z -преобразование Фишера и предварительно устанавливают интервальную оценку для Z :

$$Z' - t_{\gamma} \sqrt{\frac{1}{n-l-3}} \leq Z \leq Z' + t_{\gamma} \sqrt{\frac{1}{n-l-3}} \quad (1.6)$$

где t_{γ} вычисляют по таблице интегральной функции Лапласа (табл. 1 приложения) из условия:

$$\Phi(t_{\gamma}) = \gamma.$$

Значение Z' определяют по таблице Z -преобразования (табл. 6 приложения) по найденному значению r . Функция нечетная, т. е.:

$$Z'(-r) = -Z'(r).$$

Обратный переход от Z к ρ осуществляют также по таблице Z -преобразования, после использования которой получают интервальную оценку для ρ с надежностью γ :

$$r_{\min} \leq \rho \leq r_{\max}.$$

Таким образом, с вероятностью γ гарантируется, что генеральный коэффициент корреляции ρ будет находиться в интервале $[r_{\min}, r_{\max}]$.

Значимость множественного коэффициента корреляции (или его квадрата – коэффициента детерминации) проверяется по F -критерию.

Например, для множественного коэффициента корреляции проверка значимости сводится к проверке гипотезы, что генеральный множественный коэффициент корреляции равен нулю, т. е. $H_0: \rho_{1/2, \dots, k} = 0$, а наблюдаемое значение статистики находится по формуле:

$$F_{\text{набл}} = \frac{\frac{1}{k-1} r_{1/2, \dots, k}^2}{\frac{1}{n-k} (1 - r_{1/2, \dots, k}^2)}. \quad (1.7)$$

Множественный коэффициент корреляции считается значимым, т. е. имеет место линейная статистическая зависимость, между X_1 и остальными факторами $X_2, \dots, X_k$, если: $F_{\text{набл.}} > F_{\text{кр.}}(\alpha, k - 1, n - k)$, где $F_{\text{кр.}}$ определяется по таблице, F-распределения для заданных α , $\nu_1 = k - 1$, $\nu_2 = n - k$.

1.2. Тренировочный пример

Деятельность $n = 8$ карьеров характеризуется себестоимостью 1 т. песка (X_1), сменной добычей песка (X_2) и фондоотдачей (X_3). Значения показателей представлены в таблице.

X_1 (тыс.руб)	30	20	40	35	45	25	50	30
X_2 (тыс.руб)	20	30	50	70	80	20	90	25
X_3	20	25	20	15	10	30	10	20

Требуется:

1. Оценить параметры генеральной совокупности, которая предполагается нормально распределенной;
2. При $\alpha = 0.05$ проверить значимость частных коэффициентов корреляции $\rho_{12/3}$, $\rho_{13/2}$ и $\rho_{23/1}$ и при $\gamma = 0.95$, построить интервальную оценку для $\rho_{13/2}$.
3. Найти точечную оценку множественного коэффициента корреляции $\rho_{1/23}$ и при $\alpha = 0.05$ проверить его значимость.

Решение:

1. Найдем значения средних арифметических ($\bar{x}_j$) и средних квадратических отклонений (S_j) где $j=1, 2, 3$, а также парных коэффициентов корреляции r_{12} , r_{13} и r_{23} по формулам:

$$\bar{x}_1 = \frac{30 + 20 + 40 + 35 + 45 + 25 + 50 + 30}{8} = 34.375 \text{ тыс. руб.}$$

$$\bar{x}_2 = 48.125 \text{ т.руб.}$$

$$\bar{x}_3 = 18.75$$

$$S_1 = 9.49$$

$$S_2 = 26.68 \text{ т.руб}$$

$$S_3 = 6.48$$

$$r_{12} = \frac{\overline{x_1 x_2} - \bar{x}_1 \bar{x}_2}{S_1 S_2} = \frac{1875 - 34.375 \times 48.125}{9.49 \times 26.68} = \frac{220.70}{9.49 \times 26.68} = 0.871$$

$$\text{где } \overline{x_1 x_2} = \frac{1}{n} \sum_{i=1}^n x_{i1} x_{i2} = \frac{1}{8} (30 \times 20 + 20 \times 30 + 40 \times 50 + \dots + 30 \times 25) = 1875$$

В результате расчетов получим:

$$\bar{X} = \begin{pmatrix} 34.38 \\ 48.12 \\ 18.75 \end{pmatrix}; \quad S = \begin{pmatrix} 9.49 \\ 26.68 \\ 6.48 \end{pmatrix}; \quad R = \begin{pmatrix} 1 & 0.871 & -0.874 \\ 0.871 & 1 & -0.879 \\ -0.874 & -0.879 & 1 \end{pmatrix}$$

2. Предварительно найдем точечные оценки частных коэффициентов корреляции из выражения:

$$r_{12/3} = -\frac{R_{12}}{\sqrt{R_{11} \times R_{22}}}, \text{ где } R_{12} - \text{алгебраическое дополнение элемента } r_{12}$$

корреляционной матрицы R , а R_{11} и R_{22} алгебраические дополнения 1-го и 2-го диагонального элемента этой матрицы.

$$R_{12} = (-1)^3 \times \begin{vmatrix} 0.871 & -0.879 \\ -0.874 & 1 \end{vmatrix} = -0.103$$

$$R_{11} = (-1)^2 \times \begin{vmatrix} 1 & -0.879 \\ -0.879 & 1 \end{vmatrix} = 0.227$$

$$R_{22} = (-1)^4 \times \begin{vmatrix} 1 & -0.874 \\ -0.874 & 1 \end{vmatrix} = 0.236$$

$$r_{12/3} = \frac{0.103}{\sqrt{0.227 \times 0.236}} = 0.445$$

Аналогично находим: $r_{13/2} = -0.462$ и $r_{23/1} = -0.494$

Для проверки значимости частных коэффициентов корреляции найдем $g_{кр}(\alpha = 0.05, \nu = n - l - 2 = 5) = 0.754$, где l – порядок коэффициента корреляции. В нашем примере $l = 1$.

Так как $|r| < g_{кр} = 0.754$, то гипотезы $H_0: \rho = 0$ не отвергаются, т. е. предположение о равенстве его нулю не противоречит наблюдениям, но $n = 8$ мало.

Определим интервальную оценку для $\rho_{13/2}$ при $\gamma = 0.95$. Для этого используем Z -преобразование Фишера и предварительно найдем интервальную оценку для Z из условия:

$$Z \in \left[Z' \pm t \sqrt{\frac{1}{n-l-3}} \right].$$

По таблице Z -преобразования Фишера для $r_{13/2} = -0.462$, учитывая, что $Z'(-r) = -Z'(r)$, будем иметь $Z' = -0.497$. По таблице нормального закона, из условия $\Phi(t) = 0.95$, найдем $t = 1.96$.

Тогда,

$$Z \in \left[-0.497 \pm 1.96 \sqrt{\frac{1}{8-4}} \right],$$

откуда, $Z \in [-1.477, 0.483]$.

По таблице Z-преобразования для $Z_{\min} = -1.477$ и $Z_{\max} = 0.483$ найдем интервальную оценку для $\rho_{13/2}$:

$$\rho_{13/2} \in [-0.9, 0.45].$$

Полученная интервальная оценка подтверждает вывод о незначимости частного коэффициента корреляции $\rho_{13/2}$, т. к. нуль находится внутри доверительного интервала.

3. Найдем точечную оценку множественного коэффициента корреляции $\rho_{13/2}$ и при $\alpha = 0.05$ проверим его значимость.

Точечная оценка определяется по формуле:

$$r_{1/23} = \sqrt{1 - \frac{|R|}{R_{11}}}, \text{ где } |R| - \text{определитель корреляционной матрицы.}$$

$$|R| = 1 + 0.871(-0.879)(-0.874) + 0.871(-0.879)(-0.874) - (0.874)^2 - 0.871^2 - (-0.879)^2 - (-0.879)^2 = 0.043$$

$$r_{1/23} = \sqrt{1 - \frac{0.043}{0.227}} = 0.90$$

Проверим гипотезу $H_0: \rho_{1/23} = 0$

$$F_{\text{набл.}} = \frac{\frac{1}{2} r_{1/23}^2}{\frac{1}{n-l-1} (1 - r_{1/23}^2)} = \frac{\frac{1}{2} 0.81}{\frac{1}{5} 0.19} = 10.66,$$

где $l=2$. Критическое значение по таблице F-распределения,

$$F_{\text{кр.}}(\alpha=0.05, v_1=2, v_2=5) = 5.79$$

Т. к. $F_{\text{набл.}} > F_{\text{кр.}}$, то гипотеза H_0 отвергается, т. е. множественный коэффициент корреляции не равен нулю ($\rho_{1/23} \neq 0$).