

Глава 2. Регрессионный анализ

2.1. Основы регрессионного анализа

Регрессионный анализ – это статистический метод исследования зависимости случайной величины Y от переменных X_j ($j = 1, 2, \dots, k$), рассматриваемых в регрессионном анализе как неслучайные величины независимо от истинного закона распределения X_j .

Обычно предполагается, что случайная величина Y имеет нормальный закон распределения с условным математическим ожиданием $\tilde{Y} = \varphi(x_1, \dots, x_k)$, являющимся функцией от аргументов x_j , и с постоянной, не зависящей от аргументов дисперсией σ^2 .

Для проведения регрессионного анализа из $(k+1)$ -мерной генеральной совокупности $(Y, X_1, X_2, \dots, X_j, \dots, X_k)$ берется выборка объемом n и каждое i -ое наблюдение (объект) характеризуется значениями переменных $(y_i, x_{i1}, x_{i2}, \dots, x_{ij}, \dots, x_{ik})$, где x_{ij} – значение j -ой переменной для i -го наблюдения ($i=1, 2, \dots, n$), y_i – значение результативного признака для i -го наблюдения.

Наиболее часто используемая множественная линейная модель регрессионного анализа имеет вид:

$$y = \beta_0 + \beta_1 x_{i1} + \dots + \beta_j x_{ij} + \dots + \beta_k x_{ik} + \varepsilon_i \quad (2.1)$$

где ε_i – случайные ошибки наблюдения, независимые между собой, имеют нулевую среднюю и дисперсию σ^2 .

Отметим, что модель (2.1) справедлива для всех $i = 1, 2, \dots, n$, линейна относительно неизвестных параметров $\beta_0, \beta_1, \dots, \beta_j, \dots, \beta_k$ и аргументов.

Как следует из (2.1) коэффициент регрессии β_j показывает, на какую величину в среднем изменится результативный признак Y , если переменную X_j увеличить на единицу измерения, т. е. является нормативным коэффициентом.

В матричной форме регрессионная модель имеет вид:

$$Y = X\beta + \varepsilon \quad (2.2)$$

где Y – случайный вектор – столбец размерности $(n \times 1)$ наблюдаемых значений результативного признака $(y_1, y_2, \dots, y_n)$; X – матрица размерности $[n \times (k+1)]$ наблюдаемых значений аргументов. Элемент матрицы x_{ij} рассматривается как неслучайная величина ($i = 1, 2, \dots, n$; $j = 0, 1, 2, \dots, k$; $x_{0i} = 1$); β -вектор – столбец размерности $[(k+1) \times 1]$ неизвестных, подлежащих оценке параметров (коэффициентов регрессии) модели; ε -случайный вектор – столбец размерности $(n \times 1)$

ошибок наблюдений (остатков). Компоненты вектора ε_i независимы между собой, имеют нормальный закон распределения с нулевым математическим ожиданием ($M\varepsilon_i = 0$) и неизвестной дисперсией σ^2 ($D\varepsilon_i = \sigma^2$).

На практике рекомендуется, чтобы n превышало k не менее, чем в три раза.

$$X = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ 1 & x_{i1} & \dots & x_{ik} \\ 1 & x_{n1} & \dots & x_{nk} \end{pmatrix}; Y = \begin{pmatrix} y_1 \\ y_i \\ y_n \end{pmatrix}; \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_j \\ \beta_k \end{pmatrix}.$$

В модели (2.2) единицы в первом столбце матрицы призваны обеспечить наличие свободного члена в модели (2.1). Здесь предполагается, что существует переменная x_0 , которая во всех наблюдениях принимает значения равные 1.

Основная задача регрессионного анализа заключается в нахождении по выборке объемом n , оценки неизвестных коэффициентов регрессии $\beta_0, \beta_1, \dots, \beta_k$ модели (2.1) или вектора β в (2.2).

Так как, в регрессионном анализе x_j рассматриваются как неслучайные величины, а $M\varepsilon_i = 0$, то согласно (2.1) уравнение регрессии имеет вид:

$$\tilde{y}_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_j x_{ij} + \dots + \beta_k x_{ik} \quad (2.3)$$

для всех $i = 1, 2, \dots, n$, или в матричной форме:

$$\tilde{Y} = X\beta \quad (2.4)$$

где $\tilde{Y}$ – вектор-столбец с элементами $\tilde{y}_1, \dots, \tilde{y}_i, \dots, \tilde{y}_n$.

Для оценки вектора β наиболее часто используют метод наименьших квадратов (МНК), согласно которому в качестве оценки принимают вектор b , который минимизирует сумму квадратов отклонения наблюдаемых значений y_i от модельных значений $\tilde{y}_i$, т. е. квадратичную форму:

$$Q = (Y - X\beta)^T (Y - X\beta) = \sum_{i=1}^n (y_i - \tilde{y}_i)^2 \Rightarrow \min_{\beta_0, \beta_1, \dots, \beta_k}$$

Наблюдаемые и модельные значения показаны на рис. 2.1




Рис. 2.1 Наблюдаемые и модельные значения результативной величины y .

Дифференцируя, с учетом (2.4) и (2.3) квадратичную форму Q по $\beta_0, \beta_1, \dots, \beta_k$ и приравнявая производные нулю, получим систему нормальных уравнений:

$$\begin{cases} \frac{\partial Q}{\partial \beta_j} = 0 \\ \text{для всех } j = 0, \dots, k \end{cases}$$

решая которую и получаем вектор оценок b , где $b = (b_0 \ b_1 \dots b_k)^T$.

Согласно методу наименьших квадратов, вектор оценок коэффициентов регрессии получается по формуле:

$$b = (X^T X)^{-1} X^T Y \quad (2.5)$$

$$b = \begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ b_j \\ \vdots \\ b_k \end{pmatrix}$$

X^T – транспонированная матрица X ;

$(X^T X)^{-1}$ – матрица, обратная матрице $X^T X$.

Зная вектор оценок коэффициентов регрессии b , найдем оценку $\hat{y}_i$ уравнения регрессии :

$$\hat{y}_i = b_0 + b_1 x_{i1} + b_2 x_{i2} + \dots + b_k x_{ik} \quad (2.6)$$

Или в матричном виде: $y = X\beta$

где $\hat{y} = (\hat{y}_1 \ \hat{y}_2 \dots \hat{y}_n)^T$.

Оценка ковариационной матрицы коэффициентов регрессии вектора b определяется из выражения:

$$S(b) = \hat{S}^2 (X^T X)^{-1}, \quad (2.7)$$

$$\text{где } \hat{S}^2 = \frac{1}{n - k - 1} (Y - Xb)^T (Y - Xb). \quad (2.8)$$

Учитывая, что на главной диагонали ковариационной матрицы находятся дисперсии коэффициентов регрессии, имеем:

$$\hat{S}_{b_{(j-1)}}^2 = \hat{S}^2 [(X^T X)^{-1}]_{jj} \text{ для } j=1,2,\dots,k,k+1 \quad (2.9)$$

Значимость уравнения регрессии, т. е. гипотеза $H_0: \beta=0$ ($\beta_0=\beta_1=\dots=\beta_k=0$), проверяется по F-критерию, наблюдаемое значение которого определяется по формуле:

$$F_{\text{набл}} = \frac{Q_R / (k + 1)}{Q_{\text{ост}} / (n - k - 1)}, \quad (2.10)$$

$$\text{где, } Q_R = (Xb)^T (Xb), \quad Q_{\text{ост}} = (Y - Xb)^T (Y - Xb) = \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (2.11)$$

По таблице F-распределения для заданных α , $v_1=k+1$, $v_2=n-k-1$ находят $F_{\text{кр}}$.

Гипотеза H_0 отклоняется с вероятностью α , если $F_{\text{набл}} > F_{\text{кр}}$. Из этого следует, что уравнение является значимым, т. е. хотя бы один из коэффициентов регрессии отличен от нуля.

Для проверки значимости отдельных коэффициентов регрессии, т. е. гипотез $H_0: \beta_j=0$, где $j=1,2,\dots,k$, используют t-критерий и вычисляют: $t_{\text{набл}}(b_j) = b_j / \hat{S}_{b_j}$. По таблице t-распределения для заданного α и $v=n-k-1$, находят $t_{\text{кр}}$.

Гипотеза H_0 отвергается с вероятностью α , если $t_{\text{набл}} > t_{\text{кр}}$. Из этого следует, что соответствующий коэффициент регрессии β_j значим, т. е. $\beta_j \neq 0$. В противном случае коэффициент регрессии незначим и соответствующая переменная в модель не включается. Тогда реализуется алгоритм пошагового регрессионного анализа, состоящий в том, что исключается одна из незначимых переменных, которой соответствует минимальное по абсолютной величине значение $t_{\text{набл}}$. После этого вновь проводят регрессионный анализ с числом факторов, уменьшенным на единицу. Алгоритм заканчивается получением уравнения регрессии со значимыми коэффициентами.

Существуют и другие алгоритмы пошагового регрессионного анализа, например с последовательным включением факторов.

Наряду с точечными оценками b_j генеральных коэффициентов регрессии β_j , регрессионный анализ позволяет получать и интервальные оценки последних с доверительной вероятностью γ .

Интервальная оценка с доверительной вероятностью γ для параметра β_j имеет вид:

$$b_j - t_\alpha \hat{S}_{b_j} \leq \beta_j \leq b_j + t_\alpha \hat{S}_{b_j}, \quad (2.12)$$

где t_α находят по таблице t-распределения при вероятности $\alpha = 1-\gamma$ и числе степеней свободы $v=n-k-1$.

Интервальная оценка для уравнения регрессий $\tilde{y}$ в точке, определяемой вектором начальных условий $X^0=(1, X_1^0, X_2^0, \dots, X_k^0)^T$, равна:

$$\tilde{y} \in [(X^0)^T b \pm t_\alpha \hat{S} \sqrt{(X^0)^T (X^T X)^{-1} X^0}]. \quad (2.13)$$

Интервал оценки предсказания $\tilde{y}_{n+1}$ с доверительной вероятностью γ определяется как:

$$\tilde{y} \in [(X^0)^T b \pm t_\alpha \hat{S} \sqrt{(X^0)^T (X^T X)^{-1} X^0 + 1}], \quad (2.14)$$

где t_α определяется по таблице t-распределения при $\alpha = 1-\gamma$ и $v = n-k-1$.

По мере удаления вектора начальных условий x^0 , от вектора средних $\bar{x}$, ширина доверительного интервала при заданном γ будет увеличиваться (рис. 2.2.), где $\bar{x} = (1, \bar{x}_1, \dots, \bar{x}_k)$.




Рис. 2.2 Точечная $\hat{y}$ и интервальная оценки $[\hat{y} - \delta < \tilde{y} < \hat{y} + \delta]$ уравнения регрессии $\tilde{y} = \beta_0 + \beta_1 x$

Мультиколлинеарность

Одним из основных препятствий эффективного применения множественного регрессионного анализа, является мультиколлинеарность. Она связана с линейной зависимостью между аргументами $x_1, x_2, \dots, x_k$. В результате мультиколлинеарности, матрица парных коэффициентов корреляции и матрица $(X^T X)$ становятся слабообусловленными, то есть их определители близки к нулю.

Это вызывает неустойчивость оценок коэффициентов регрессии (2.5), большие дисперсии $\hat{S}_{b_j}^2$ оценок этих коэффициентов (2.7), т. к. в их выражении входит обратная матрица $(X^T X)^{-1}$, получение которой связано с делением на определитель матрицы $|X^T X|$. Отсюда следуют

заниженные значения $t(b_j)$. Кроме того, мультиколлинеарность приводит к завышению значения множественного коэффициента корреляции.

На практике, о наличии мультиколлинеарности, обычно судят по матрице парных коэффициентов корреляции. Если один из элементов матрицы R больше 0.8, т. е. $|r_{je}| > 0,8$, то считают, что имеет место мультиколлинеарность и в уравнение регрессии следует включать только один из показателей x_j или x_e .

Чтобы избавиться от этого негативного явления, обычно используют алгоритм пошагового регрессионного анализа или строят уравнение регрессии на главных компонентах (раздел 1.3).

2.2. Пример построения регрессионного уравнения

По данным $n=20$ сельскохозяйственных районов требуется построить регрессионную модель урожайности на основе следующих показателей:

Y – урожайность зерновых культур (ц/га);

X_1 – число колесных тракторов (приведенной мощности) на 100 га;

X_2 – число зерноуборочных комбайнов на 100 га;

X_3 – число орудий поверхностной обработки почвы на 100 га;

X_4 – количество удобрений, расходуемых на гектар;

X_5 – количество химических средств оздоровления растений, расходуемых на гектар.

Исходные данные для анализа приведены в табл. 2.2

Таблица 2.2

Исходные данные для анализа

№ п/п	Y	X_1	X_2	X_3	X_4	X_5
1	9.70	1.59	0.26	2.05	0.32	0.14
2	8.40	0.34	0.28	0.46	0.59	0.66
3	9.00	2.53	0.31	2.46	0.30	0.31
4	9.90	4.63	0.40	6.44	0.43	0.59
5	9.60	2.16	0.26	2.16	0.39	0.16
6	8.60	2.16	0.30	2.69	0.32	0.17
7	12.50	0.68	0.29	0.73	0.42	0.23
8	7.60	0.35	0.26	0.42	0.21	0.08
9	6.90	0.52	0.24	0.49	0.20	0.08
10	13.50	3.42	0.31	3.02	1.37	0.73
11	9.70	1.78	0.30	3.19	0.73	0.17
12	10.70	2.40	0.32	3.30	0.25	0.14
13	12.10	9.36	0.40	11.51	0.39	0.38
14	9.70	1.72	0.28	2.26	0.82	0.17
15	7.00	0.59	0.29	0.60	0.13	0.35
16	7.20	0.28	0.26	0.30	0.09	0.15
17	8.20	1.64	0.29	1.44	0.20	0.08
18	8.40	0.09	0.22	0.05	0.43	0.20
19	13.10	0.08	0.25	0.03	0.73	0.20
20	8.70	1.36	0.26	1.17	0.99	0.42

Решение: Предварительно, с целью анализа взаимосвязи показателей построена таблица парных коэффициентов корреляции R.

	Y	X ₁	X ₂	X ₃	X ₄	X ₅
Y	1.00	0.43	0.37	0.40	0.58	0.33
X ₁	0.43	1.00	0.85	0.98	0.11	0.34
X ₂	0.37	0.85	1.00	0.88	0.03	0.46
X ₃	0.40	0.98	0.88	1.00	0.03	0.28
X ₄	0.58	0.11	0.03	0.03	1.00	0.57
X ₅	0.33	0.34	0.46	0.28	0.57	1.00

Анализ матрицы парных коэффициентов корреляции показывает, что результативный показатель наиболее тесно связан с показателем X₄ – количеству удобрений, расходуемых на гектар ($r_{yx_4}=0.58$).

В то же время связь между признаками-аргументами достаточно тесная. Так, существует практически функциональная связь между числом колесных тракторов (X₁) и числом орудий поверхностной обработки почвы (X₃) – $r_{x_1x_3}=0.98$.

О наличии мультиколлинеарности свидетельствует также коэффициенты корреляции $r_{x_1x_2}=0.85$ и $r_{x_3x_2}=0.88$.

Чтобы продемонстрировать отрицательное влияние мультиколлинеарности, рассмотрим регрессионную модель урожайности, включив в нее все исходные показатели:

$$\hat{Y}=3.515 - 0.006X_1 + 15.542X_2 + 110X_3 + 4.475X_4 - 2.932X_5 \quad (2.15)$$

(–0.01) (0.72) (0.13) (2.90) (–0.95)

В скобках указаны $t_{\text{набл}}(b_j)$, расчетные значения t-критерия для проверки гипотезы о значимости коэффициента регрессии $H_0: \beta_j=0$, $j=1, 2, 3, 4, 5$. Критическое значение $t_{\text{кр}}=1.76$ найдено по таблице t-распределения при уровне значимости $\alpha=0.1$ и числе степеней свободы $\nu=14$. Из уравнения следует, что статистически значимым является коэффициент регрессии только при X₄, так как $|t_4|=2.90 > t_{\text{кр}}=1.76$. Не поддаются экономической интерпретации отрицательные знаки коэффициентов регрессии при X₁ и X₅, из чего следует, что повышение насыщенности сельского хозяйства колесными тракторами (X₁) и средствами оздоровления растений (X₅) отрицательно сказывается на урожайности. Таким образом, полученное уравнение регрессии не приемлемо.

После реализации алгоритма пошагового регрессионного анализа, с исключением переменных и учетом того, что в уравнение должна войти только одна из трех тесно связанных переменных (X_1 , X_2 или X_3) получаем окончательное уравнение регрессии:

$$\hat{Y} = 7.342 + 0.345X_1 + 3.294X_4 \quad (2.16)$$

(11.12) (2.09) (3.02)

В уравнение (2.16) включен X_1 , как определяющий из трех показателей.

Уравнение значимо при $\alpha=0.05$, т.к. $F_{\text{набл}}=266 > F_{\text{кр}}=3.20$, найденного по таблице F-распределения при $\alpha=0.05$; $\nu_1=3$ и $\nu_2=17$. Значимы и все коэффициенты регрессии β_1 и β_4 в уравнении $|t_j| > t_{\text{кр}}$ ($\alpha=0.05$; $\nu=17$) = 2.11. Коэффициент регрессии β_1 следует признать значимым ($\beta_1 \neq 0$) из экономических соображений, при этом $t_1=2.09$ лишь незначительно меньше $t_{\text{кр}}=2.11$. При $\alpha=0.1$, $t_{\text{кр}}=1.74$ и β_1 статистически значим.

Из уравнения регрессии следует, что увеличение на 1 числа тракторов на 100 га пашни приводит к росту урожайности зерновых в среднем на 0.345 ц/га ($b_1=0.345$).

Коэффициенты эластичности $\mathcal{E}_1=0.068$ и $\mathcal{E}_4=0.161$ показывают, что при увеличении показателей X_1 и X_4 на 1% урожайность зерновых повышается соответственно на 0.068% и 0.161%, ($\mathcal{E}_j = b_j \frac{\bar{X}_j}{\bar{Y}}$).

Множественный коэффициент детерминации $r_y^2=0.469$ свидетельствует о том, что только 46.9% вариации урожайности объясняется вошедшими в модель показателями (X_1 и X_4), то есть насыщенностью растениеводства тракторами и удобрениями. Остальная часть вариации обусловлена действием неучтенных факторов (X_2 , X_3 , X_5 , погодных условий и др.). Средняя относительная ошибка аппроксимации $\bar{\delta}=10.5\%$ характеризует адекватность модели, также как и величина остаточной дисперсии $S^2=1.97$.

2.3. Тренировочный пример

По данным годовых отчетов, десяти ($n=10$) машиностроительных предприятий, провести регрессионный анализ зависимости производительности труда y (млн. руб. на чел.), от объема производства x (млрд. руб.). Предполагается линейная модель, т.е. $\tilde{y} = \beta_0 + \beta_1 x$.

Таблица 2.1

Исходная информация для анализа и результаты расчетов

N п/п (i)	y_i	x_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$
1	2,1	3	2,77	-0,67
2	2,8	4	3,52	-0,72
3	3,2	5	4,27	-1,07
4	4,5	5	4,27	0,23
5	4,8	5	4,27	0,53
6	4,9	5	4,27	0,63
7	5,5	6	5,02	0,48
8	6,5	7	5,77	0,73
9	12,1	15	11,75	0,35
10	15,1	20	15,50	-0,4

Решение: Определим вектор оценок b коэффициентов регрессии. Согласно методу наименьших квадратов, вектор b получается из выражения:

$$b = (x^T x)^{-1} x^T y.$$

Воспользовавшись правилами умножения матриц будем иметь:

$$x^T x = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 3 & 4 & 5 & 5 & 5 & 5 & 6 & 7 & 15 & 20 \end{pmatrix} \begin{pmatrix} 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 5 \\ 1 & 5 \\ 1 & 5 \\ 1 & 6 \\ 1 & 7 \\ 1 & 15 \\ 1 & 20 \end{pmatrix} = \begin{pmatrix} 10 & 75 \\ 75 & 835 \end{pmatrix}$$

В матрице $(x^T x)$ число 10, лежащее на пересечении 1-й строки и 1-го столбца, получено как сумма произведений элементов 1-й строки матрицы x^T и 1-го столбца матрицы x , а число 75, лежащее на пересечении 1-й строки и 2-го столбца, как сумма произведений элементов 1-й строки матрицы x^T и 2-го столбца матрицы x и т.д.

$$x^T y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 3 & 4 & 5 & 5 & 5 & 5 & 6 & 7 & 15 & 20 \end{pmatrix} \begin{pmatrix} 2,1 \\ 2,8 \\ 3,2 \\ 4,5 \\ 4,8 \\ 4,9 \\ 5,5 \\ 6,5 \\ 12,1 \\ 15,1 \end{pmatrix} = \begin{pmatrix} 61,4 \\ 664,5 \end{pmatrix}$$

Найдем обратную матрицу:

$$(x^T x)^{-1} = \frac{1}{10 \cdot 835 - (75)^2} \begin{pmatrix} 835 & -75 \\ -75 & 10 \end{pmatrix} = \begin{pmatrix} 0,306422 & -0,0275229 \\ -0,0275229 & 0,0036697 \end{pmatrix},$$

Тогда вектор оценок коэффициентов регрессии равен:

$$b = \begin{pmatrix} 0,306422 & -0,0275229 \\ -0,0275229 & 0,0036697 \end{pmatrix} \cdot \begin{pmatrix} 61,4 \\ 664,5 \end{pmatrix} = \begin{pmatrix} 0,5253430 \\ 0,7486096 \end{pmatrix},$$

а оценка уравнения регрессии будет иметь вид: $\hat{y} = 0,52534 + 0,74861x$.

Перейдем к статистическому анализу полученного уравнения регрессии: проверке значимости уравнения и его коэффициентов, исследованию абсолютных $e_i = y_i - \hat{y}$ и относительных $\delta_i = \frac{y_i - \hat{y}_i}{y_i} 100\%$ ошибок аппроксимации.

Предварительно определим вектор модельных значений результативного показателя $\hat{y}$:

$$\hat{y} = xb = \begin{pmatrix} 1 & 3 \\ 1 & 4 \\ 1 & 5 \\ 1 & 5 \\ 1 & 5 \\ 1 & 5 \\ 1 & 6 \\ 1 & 7 \\ 1 & 15 \\ 1 & 20 \end{pmatrix} \cdot \begin{pmatrix} 0,5253430 \\ 0,7486096 \end{pmatrix} = \begin{pmatrix} 2,77 \\ 3,52 \\ 4,27 \\ 4,27 \\ 4,27 \\ 4,27 \\ 5,02 \\ 5,77 \\ 11,75 \\ 15,50 \end{pmatrix}.$$

Тогда,

$$Q_{-□} = (y - \hat{y})^T (y - \hat{y}) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = 3,9847314.$$

Откуда согласно (2.8.) несмещенная оценка остаточной дисперсии равна:

$$\hat{\sigma}^2 = \frac{1}{8} \cdot 3,9847314 = 0,49809176 ,$$

а оценка среднего квадратического отклонения:

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = 0,70575616 .$$

Проверим на уровне значимости $\alpha=0,05$ значимость уравнения регрессии, т.е. гипотезу $H_0: \beta=0$ ($\beta_0=\beta_1=0$). Для этого вычисляем согласно (2.10.) величину

$$F_{\text{набл}} = \frac{\frac{1}{2} Q_R}{\frac{1}{8} Q_{\text{ост}}} = \frac{264,84958}{0,49809176} = 531,72849$$

По таблице F-распределения для $\alpha=0,05$, $v_1 = 2$ и $v_2 = 8$ находим $F_{\text{кр}}=4,46$. Так как $F_{\text{набл}} > F_{\text{кр}}$, то уравнение является значимым.

Найдем оценку ковариационной матрицы вектора b :

$$\begin{aligned} \hat{S}(b) &= \hat{\sigma}^2 (X^T X)^{-1} = \begin{pmatrix} 0,306422 & -0,0275299 \\ -0,0275229 & 0,0036697 \end{pmatrix} \cdot 0,49809176 = \\ &= \begin{pmatrix} 0,15262627 & -0,013712416 \\ -0,013712416 & 0,0018278473 \end{pmatrix} \end{aligned}$$

Отсюда получаем несмещенные оценки дисперсий и среднеквадратических отклонений коэффициентов регрессии:

$$\begin{aligned} \hat{\sigma}_{b_0}^2 &= 0,15262627 & \hat{\sigma}_{b_0} &= 0,3906741 \\ \hat{\sigma}_{b_1}^2 &= 0,0018278473 & \hat{\sigma}_{b_1} &= 0,0427527 . \end{aligned}$$

Для проверки значимости коэффициента регрессии, т.е. гипотезы $H_0: \beta_1=0$, находим по таблице t-распределения при $\alpha=0,05$, $v=8$ значение $t_{\text{кр}}=2,31$:

$$t_{\text{набл}}(b_1) = \frac{b_1}{\hat{\sigma}_{b_1}} = \frac{0,74861}{0,0427527} = 17,5102 .$$

Так как $t_{\text{набл}}(b_1)=17,51$, больше $t_{\text{кр}}=2,31$, то коэффициент регрессии β_1 значимо отличается от нуля. Таким образом, окончательное уравнение регрессии имеет вид: $\hat{y} = 0,52534 + 0,74861x$.

Определим интервальные оценки коэффициентов уравнения с доверительной вероятностью $\gamma=0,95$.

Из (2.12.) следует:

$$\begin{aligned} \beta_0 &\in [0,525 \pm 2,31 \times 0,391], \text{ откуда } -0,378 \leq \beta_0 \leq 1,428 \text{ и} \\ \beta_1 &\in [0,74861 \pm 2,31 \times 0,0428], \text{ откуда } 0,650 \leq \beta_1 \leq 0,847. \end{aligned}$$